

# 组合优化与凸优化作业 2

胡冠宇

所有代码见附件或 GitHub 备份<sup>1</sup>.

## 1

使用共轭梯度法求解

$$\min_{\mathbf{x}} f(\mathbf{x}) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2,$$

得到最优解  $\mathbf{x}^* = (-1, 1.5)^T$ , 最优值  $f(\mathbf{x}^*) = -1.25$ .

## 2

分别使用 Golden Search, Fibonacci Search, Bisection Search 求解

$$\min_x f(x) = 2x^2 - x - 1 \tag{1}$$

和

$$\min_x f(x) = 3x^2 - x - 1, \tag{2}$$

结果见表 1 和表 2.

表 1 不同方法求解公式 (1) 的结果

方法	最优解	最优值	迭代轮次
Golden Search	0.2574	-1.1249	8
Fibonacci Search	0.2500	-1.1250	30
Bisection Search	0.2500	-1.1250	2
ShubertPiyavskii Search ( $l = 2$ )	0.2500	-1.1250	0

<sup>1</sup><https://github.com/ikaroinory/convex-opt/tree/main/homework/homework2/src>

表 2 不同方法求解公式 (2) 的结果

方法	最优解	最优值	迭代轮次
Golden Search	3.6086	-39.8798	12
Fibonacci Search	3.6000	-39.8800	36
Bisection Search	3.5889	-39.8796	9
ShubertPiyavskii Search ( $l = 5$ )	0.0000	0.0000	0

## 3

分别使用 Goldstein 法, Armijo 法, Wolfe-Powell 法及改进 Wolfe-Powell 法求解

$$\min_{\lambda} f(\mathbf{x} + \lambda \mathbf{d}), \quad (3)$$

其中  $f(\mathbf{x}) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$ , 结果见表 3 所示.

表 3 不同方法求解公式 (3) 的结果

方法	最优解	迭代轮次
Goldstein	0.0042	52
Armijo	0.0039	8
WolfePowell	0.0001	13
Improved WolfePowell	0.0020	9

## 4

(1)

$$\begin{aligned}
 \partial f(\mathbf{0}) &= \{\mathbf{g} \in \mathbb{R}^3 \mid f(\mathbf{x}) \geq f(\mathbf{0}) + \mathbf{g}^T \mathbf{x}, f(\mathbf{x}) = \max\{|\mathbf{x}|\}\} \\
 &= \{\mathbf{g} \in \mathbb{R}^3 \mid \max\{|\mathbf{x}|\} \geq \mathbf{g}^T \mathbf{x}\} \\
 &= \{\mathbf{g} \in \mathbb{R}^3 \mid \|\mathbf{g}\|_1 \leq (1, 1, 1)^T\}.
 \end{aligned}$$

(2)

$$\begin{aligned}
\partial f(0) &= \{g \in \mathbb{R} \mid f(x) \geq f(0) + gx, f(x) = e^{|x|}\} \\
&= \{g \in \mathbb{R} \mid e^{|x|} \geq 1 + gx\} \\
&= [-1, 1].
\end{aligned}$$

(3)

$$\partial f(\mathbf{x}_0) = \{\mathbf{g} \in \mathbb{R}^2 \mid f(\mathbf{x}) \geq f(\mathbf{x}_0) + \mathbf{g}^T \mathbf{x}, f(\mathbf{x}) = \max\{f_1(\mathbf{x}), f_2(\mathbf{x})\}\},$$

其中  $\mathbf{x}_0 = (1, 1)$ ,  $f_1(\mathbf{x}) = x_1 + x_2 - 1$ ,  $f_2(\mathbf{x}) = x_1 - x_2 + 1$ . 由 Finite pointwise maximum 可知,

$$\partial f(\mathbf{x}_0) = \text{conv} \left\{ \bigcup_{i \in \{i \mid f_i(\mathbf{x}_0) = f(\mathbf{x}_0)\}} \partial f_i(\mathbf{x}_0) \right\} = \{(1, \lambda)^T \mid \lambda \in [-1, 1]\}.$$

5

使用 DFP 法求解

$$\min_{x_1, x_2} 10x_1^2 + x_2^2, \quad (4)$$

得到最优解  $\mathbf{x}^* = (0, 0)^T$ , 最优值  $f(\mathbf{x}^*) = 0$ .

6

使用 BFGS 法求解

$$\min_{x_1, x_2} x_1^2 + 4x_2^2 - 4x_1 - 8x_2,$$

得到最优解  $\mathbf{x}^* = (2, 1)^T$ , 最优值  $f(\mathbf{x}^*) = -8$ .

7

分别使用 DFP 法, BFGS 法和共轭梯度法 (FR) 求解

$$\min_{x_1, x_2} x_1^2 + x_2^2 - x_1x_2 - 10x_1 - 4x_2 + 60, \quad (5)$$

结果见表 4.

表 4 不同方法求解公式 (5) 的结果

方法	最优解	最优值	迭代轮次
DFP	$(0, 0)^T$	60	0
BFGS	$(0, 0)^T$	60	0
Conjugate Gradient (FR)	$(-0.1014, -0.0405)^T$	61.1836	1

## 8

1. 考虑凸函数  $f(\mathbf{x})$  一阶连续可导, 假设其梯度 Lipschitz 连续, 即

$$\|\nabla f(\mathbf{y}) - \nabla f(\mathbf{x})\| \leq L\|\mathbf{y} - \mathbf{x}\|, \quad \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n.$$

设梯度下降法迭代形式为

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \lambda \nabla f(\mathbf{x}_k), \quad \lambda_k \in \left(0, \frac{2}{L}\right),$$

则有

$$f(\mathbf{x}_{k+1}) \leq f(\mathbf{x}_k) - \frac{\lambda_k}{2} \|\nabla f(\mathbf{x}_k)\|^2,$$

由此得出梯度下降法是单调下降的, 且目标函数值逐步趋于最小值. 进一步地, 如果  $f(\mathbf{x})$  是强凸的, 则可得线性收敛率

$$\|\mathbf{x}_k - \mathbf{x}^*\| \leq C\rho^k, \quad \rho \in (0, 1).$$

2. 设  $f(\mathbf{x})$  在最优点附近二阶可导且 Hessian 矩阵正定. 由 Newton 法迭代公式

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \lambda_k [\nabla^2 f(\mathbf{x}_k)]^{-1} \nabla f(\mathbf{x}_k)$$

得到, 在最优点  $\mathbf{x}^*$  附近, 若满足

$$\begin{cases} \nabla f(\mathbf{x}^*) = \mathbf{0}, \\ \nabla^2 f(\mathbf{x}^*) > \mathbf{0}, \\ \text{Hessian 连续}, \end{cases}$$

则容易证明

$$\|\mathbf{x}_{k+1} - \mathbf{x}^*\| \leq C\|\mathbf{x}_k - \mathbf{x}^*\|^2.$$

即牛顿法具有二次收敛速度.

3. 设目标函数为

$$\min_{\mathbf{x}} f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T \mathbf{Q} \mathbf{x} + \mathbf{c}^T \mathbf{x},$$

其中矩阵  $\mathbf{Q}$  正定, 且梯度

$$\nabla f(\mathbf{x}) = \mathbf{Q} \mathbf{x} + \mathbf{c}.$$

使用梯度下降法, 有

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \lambda_k (\mathbf{Q} \mathbf{x}_k + \mathbf{c}).$$

设最优解为  $\mathbf{x}^*$ , 且满足  $\mathbf{Q} \mathbf{x}^* + \mathbf{c} = \mathbf{0}$ , 解得  $\mathbf{x}^* = -\mathbf{Q}^{-1} \mathbf{c}$ . 定义误差  $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}^*$ , 则有

$$\begin{aligned} \mathbf{e}_{k+1} &= \mathbf{x}_{k+1} - \mathbf{x}^* \\ &= \mathbf{x}_k - \lambda_k (\mathbf{Q} \mathbf{x}_k + \mathbf{c}) - \mathbf{x}^* \\ &= \mathbf{e}_k - \lambda_k \mathbf{Q} \mathbf{e}_k \\ &= (\mathbf{I} - \lambda_k \mathbf{Q}) \mathbf{e}_k, \end{aligned}$$

于是

$$\mathbf{e}_k = (\mathbf{I} - \lambda_k \mathbf{Q})^k \mathbf{e}_0.$$

因此, 只要选择合适的  $\lambda_k$ , 则收敛因子  $\|\mathbf{I} - \lambda_k \mathbf{Q}\| < 1$ , 从而保证梯度下降线性收敛.

## 9

无约束优化问题形式为

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}),$$

其中  $f(\mathbf{x})$  为目标函数, 其定义在整个空间内, 且无其他约束条件.

无约束优化问题的求解通常有两类方法

### 1. 梯度类方法.

梯度类方法利用梯度或 Hessian 矩阵信息, 来选取合适的搜索方向, 即

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \lambda_k \nabla f(\mathbf{x}^{(k)}).$$

常见的梯度类方法有最速下降法, 牛顿法, 共轭梯度法等.

### 2. 搜索方法.

搜索方法不使用任何梯度或 Hessian 矩阵信息, 直接根据约束在空间中挑选线性无关的方向搜索. 常见的搜索方法有模式搜索, Rosenbrock 法, 单纯形搜索, Powell 方

法等.

求解无约束优化问题通常有两个步骤:

1. 确定搜索方向.
2. 确定搜索步长.

非凸优化难以求解, 因此在理论和工程中常希望将其转化为凸问题. 常用方法有:

1. 松弛.

将原问题的非凸部分用凸函数近似或放松.

2. 凸包方法.

对非凸函数取其最紧凸上界, 构成凸优化问题.

3. 重参数化或替代变量.

通过变量替换, 使目标函数或约束变凸.

4. 局部凸化.

将非凸函数在某个邻域内近似为凸函数.

5. 正则化与惩罚项.

加入凸正则项, 引导目标函数变得更凸.

## 10

最速下降法, Newton 法, 修正 Newton 法的计算公式可以统一描述为

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \lambda_k \mathbf{H}_k \nabla f(\mathbf{x}_k),$$

其中,  $\lambda_k$  为迭代步长,  $\mathbf{H}_k$  为正定对称矩阵.

最速下降法, Newton 法, 修正 Newton 法的不同点在于:

- 最速下降法:  $\mathbf{H}_k = \mathbf{I}$ , 即

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \lambda_k \nabla f(\mathbf{x}_k).$$

最速下降法收敛速度慢, 易出现锯齿形路径, 尤其在等高线椭圆扁长时.

- Newton 法:  $\mathbf{H}_k = [\nabla^2 f(\mathbf{x}_k)]^{-1}$ , 即

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \lambda_k [\nabla^2 f(\mathbf{x}_k)]^{-1} \nabla f(\mathbf{x}_k).$$

Newton 法使用了二阶信息, 因此收敛速度快, 但 Hessian 矩阵计算复杂, 且可能不可逆或非正定.

- 修正 Newton 法:  $\mathbf{B}_k \approx \nabla^2 f(\mathbf{x}_k)$ , 即

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \lambda_k \mathbf{B}_k^{-1} \nabla f(\mathbf{x}_k).$$

修正 Newton 法避免直接计算 Hessian 矩阵, 且收敛速度接近牛顿法, 计算开销远小于牛顿法.

变尺度法的核心思想为: 不断调整目标函数的度量方式, 改变梯度方向的尺度或几何结构, 以更快地逼近最优解.

## 11

使用含有动量 (momentum=0.9) 的随机梯度优化器法求解公式 (4), 得到最优解  $\mathbf{x}^* = (0, 0)^T$ , 最优值  $f(\mathbf{x}^*) = 0$ .

## 12

观察 GDN<sup>[1]2</sup> 中 Embedding 层的参数分布 (如图 1 所示), 参数基本分布在一个区域, 因此满足低维特性.

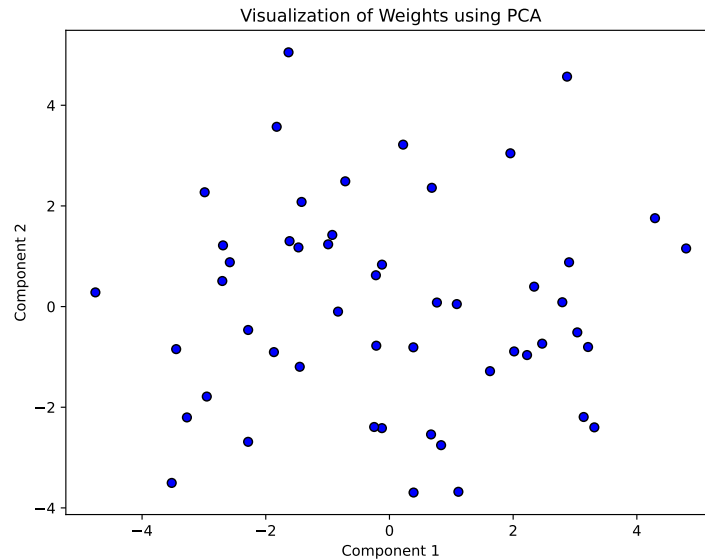


图 1 使用 PCA 对 GDN 的 Embedding 层降维后的结果

<sup>2</sup>本文使用复现的 GDN 模型, 代码见<https://github.com/ikaroinory/GDN>.

## 13

### 1. Crested Porcupine Optimizer (CPO)<sup>[2]</sup>.

该算法受到豪猪的防御行为的启发,旨在尽可能多地解决这些缺点,以准确解决一些优化问题,特别是大规模优化问题. 现有的大多数元启发式算法都试图模拟动物的攻击行为,但 CPO 首次尝试模拟豪猪的防御行为,以提出一种具有不同特征的新型元启发式算法,该算法可能在大量优化问题中取得优异的结果. 豪猪通过四种不同的方式自卫: 视觉,听觉,嗅觉和物理攻击. 在 CPO 中,声音和视觉防御机制代表探索行为,而其他机制代表利用行为. 此外,一种名为循环种群减少技术的新颖策略已与所提出的优化器相结合,以模拟假设: 只有部分豪猪在感知到威胁时才会激活防御机制. 该策略在保持种群多样性的同时,加快了向近最优解的收敛速度.

### 2. Puma Optimizer (PO)<sup>[3]</sup>.

文章提出了一种新的优化算法——美洲狮优化器 (PO),其灵感源自美洲狮的智慧和生命. 该算法在探索和开发的每个阶段都提出了独特而强大的机制,从而提高了算法在各种优化问题中的性能. 此外,文章还提出了一种新型智能机制,即一种用于相变的超启发式算法. 利用这种机制,PO 算法可以在优化操作期间执行相变操作,并平衡两个阶段. 每个阶段都会根据问题的性质自动调整.

## 14

Krylov 子空间方法是一类用于求解大型稀疏线性方程组的迭代算法,其基本思想是利用矩阵和残差向量生成的 Krylov 子空间,在该子空间内寻找近似解. 对于线性系统  $\mathbf{Ax} = \mathbf{b}$ ,从初始残差  $\mathbf{r}_0 = \mathbf{b} - \mathbf{Ax}_0$  出发,通过不断地计算  $\mathbf{A}$  与前一残差的乘积,生成 Krylov 子空间

$$\mathcal{K}_k(\mathbf{A}, \mathbf{r}_0) = \text{span}\{\mathbf{r}_0, \mathbf{Ar}_0, \mathbf{A}^2\mathbf{r}_0, \dots, \mathbf{A}^{k-1}\mathbf{r}_0\},$$

然后在该子空间中寻找使残差最小的近似解.

子空间投影方法在数值线性代数中有广泛应用,典型的包括:

1. 求解线性方程组. 如共轭梯度法 (CG) 和广义最小残差法 (GMRES),通过在 Krylov 子空间中投影,寻找近似解.
2. 特征值问题. Lanczos 方法和 Arnoldi 方法通过在 Krylov 子空间中投影,逼近矩阵的特征值和特征向量.
3. 预处理技术. 在迭代求解过程中,通过子空间投影构造预处理矩阵,加速收敛.

以 GMRES 方法为例,考虑线性系统  $\mathbf{Ax} = \mathbf{b}$ ,其中  $\mathbf{A}$  为非对称矩阵. GMRES 通过构造 Krylov 子空间  $\mathcal{K}_k(\mathbf{A}, \mathbf{r}_0)$ ,在其中寻找使残差范数最小的近似解. 具体步骤如下:



1. Arnoldi 正交化. 生成正交基  $(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k)$ , 将  $\mathbf{A}$  在该基下投影为上 Hessenberg 矩阵  $\mathbf{H}_k$ .
2. 最小化残差. 求解最小二乘问题

$$\min_{\mathbf{y}} |\mathbf{H}_k \mathbf{y} - \beta \mathbf{e}_1|,$$

得到  $\mathbf{y}_k$ , 进而计算近似解  $\mathbf{x}_k = \mathbf{V}_k \mathbf{y}_k$ , 其中  $\mathbf{V}_k = (\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k)$ .

在实际应用中, GMRES 方法通常表现出良好的收敛性, 特别是对于非对称或非正定矩阵.

GMRES 方法与共轭梯度法的比较:

1. 适用范围: 共轭梯度法适用于对称正定矩阵, 而 GMRES 可处理任意矩阵, 特别是非对称或非正定矩阵.
2. 存储需求: GMRES 需要存储 Krylov 子空间的全部基向量, 存储需求随迭代次数增加, 可能导致内存问题. 共轭梯度法仅需存储少量向量, 存储需求固定.
3. 收敛性: 对于对称正定矩阵, CG 方法通常收敛速度快于 GMRES. 然而, 对于非对称或非正定矩阵, GMRES 可能是更合适的选择.

## 15

共轭函数定义如下:

**定义 1.** 对于函数  $f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{-\infty, +\infty\}$ , 其共轭函数  $f^*$  定义为

$$f^*(\mathbf{y}) = \sup_{\mathbf{x} \in \mathbb{R}^n} \{\langle \mathbf{y}, \mathbf{x} \rangle - f(\mathbf{x})\},$$

其中  $\langle \cdot, \cdot \rangle$  为 Euclid 内积.

求解共轭函数一般有如下步骤:

1. **构造优化问题.** 由定义 1 可知, 求解共轭函数是一个关于  $\mathbf{x}$  的优化问题.
2. **求导.** 若  $f(\mathbf{x})$  可微, 找到使得梯度为零的  $\mathbf{x}$ , 即解方程

$$\nabla_{\mathbf{x}}(\langle \mathbf{y}, \mathbf{x} \rangle - f(\mathbf{x})) = \mathbf{0}.$$

3. **凸性与 Legendre 变换.** 若  $f(\mathbf{x})$  是严格凸函数, 求共轭函数的过程等价于 Legendre 变换, 即

$$f^*(\mathbf{y}) = \langle \mathbf{y}, \mathbf{x}^*(\mathbf{y}) \rangle - f(\mathbf{x}^*(\mathbf{y})),$$

其中  $\mathbf{x}^*(\mathbf{y})$  是由  $\mathbf{y} = \nabla f(\mathbf{x})$  反解得到的.

共轭函数在优化问题中扮演了关键角色, 尤其是在 Lagrange 对偶和 Fenchel 对偶中.

### 1. Lagrange 对偶.

设优化问题为

$$\begin{cases} \min_{\mathbf{x}} & f(\mathbf{x}) \\ \text{s.t.} & g_i(\mathbf{x}) \leq 0, \\ & h_j(\mathbf{x}) = 0, \end{cases}$$

则其对偶问题可通过 Lagrange 函数

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_i \lambda_i g_i(\mathbf{x}) + \sum_j \mu_j h_j(\mathbf{x})$$

用共轭函数表示目标函数, 从而推导对偶问题.

### 2. Fenchel 对偶.

给定函数  $f(\mathbf{x})$  和  $g(\mathbf{y})$ , 考虑优化问题

$$\min_{\mathbf{x}} f(\mathbf{x}) + g(\mathbf{Ax}),$$

其 Fenchel 对偶问题为

$$\max_{\mathbf{y}} f^*(-\mathbf{A}^T \mathbf{y}) - g^*(\mathbf{y}),$$

其中  $f^*$  和  $g^*$  分别为  $f$  和  $g$  的共轭函数.

共轭函数在优化理论中起到了桥梁作用, 将原始问题映射到其对偶问题, 从而提供了一种有效的分析工具。利用共轭函数, 可以深入研究优化问题的对偶结构, 如强对偶性条件, 对偶间隙以及对偶问题的解构特性。在凸优化领域, 共轭函数广泛应用于凸对偶理论, Fenchel 对偶以及拉格朗日对偶方法, 为求解复杂优化问题提供了重要的理论支撑。

## 参考文献

- [1] DENG A, HOOI B. Graph neural network-based anomaly detection in multivariate time series[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 35. 2021: 4027-4035.
- [2] ABDEL-BASSET M, MOHAMED R, ABOUHAWWASH M. Crested porcupine optimizer: A new nature-inspired metaheuristic[J]. Knowledge-Based Systems, 2024, 284: 111257.

- [3] LIAN J, HUI G, MA L, et al. Parrot optimizer: Algorithm and applications to medical problems[J]. Computers in Biology and Medicine, 2024, 172: 108064.